

DeepSeek-R1

纯强化学习驱动的推理能力涌现

Pure Reinforcement Learning Elicits Reasoning in LLMs

Nature, 2025

- 研究背景与动机
- 发展脉络与主流方法对比
- 核心方法：GRPO 算法详解
- 实验结果与消融分析
- 局限性与未来方向

数学推理

多步代数推导、几何证明、奥数竞赛题——LLM 常给出 " 看起来对但错了 " 的答案

代码生成与调试

复杂算法、多文件协调、边界条件处理——需要系统化思考而非模式匹配

科学分析

假设检验、实验设计、数据解读——需要领域知识与逻辑链条的深度结合

- 需要大量标注数据 — 传统 RLHF 依赖海量高质量 " 人类反馈数据 " ，成本极高
- 必须先做 SFT （监督微调） — GPT-4o 、 Claude 等都需要先经过 SFT 才能做 RL
- 推理链质量不可控 — CoT prompting 可以引导思考，但模型无法验证推理步骤正确性

" 大语言模型能否通过**纯强化学习**，不依赖任何监督微调，自主涌现出**推理能力**？ "

- **纯 RL** — 完全摒弃 SFT，从零开始训练（类比：AlphaGo 不学人类棋谱，自我对弈超越人类）
- **推理涌现** — 不是教模型 " 怎么推理 "，而是创造条件让推理能力自己涌现出来

发展脉络：从 " 教 " 到 " 涌现 "

6

2022

→ **CoT Prompting**

Wei et al. — 引导思考，但无法真正教会推理

2022

→ **RLHF / InstructGPT**

OpenAI — 依赖大量人工标注数据

2024.09

→ **OpenAI o1**

Extended Thinking — 黑箱，AIME 74.6%

2025.01

→ **DeepSeek-R1-Zero**

纯 RL，涌现反思能力！无标注数据

2025.01

→ **DeepSeek-R1**

冷启动 + RL + SFT，追平 o1，全开源

模型	方法	AIME 2024	MATH-500	LiveCodeBench	GPQA
GPT-4o (2024)	SFT + RLHF	9.3%	75.9%	11.0%	49.9%
Claude 3.5 Sonnet	SFT + RLHF	16.7%	78.3%	21.2%	65.0%
OpenAI o1	Extended Thinking	74.6%	85.5%	52.3%	75.7%
DeepSeek-R1-Zero	Pure RL	71.0%	96.2%	54.1%	—
DeepSeek-R1	Cold Start + RL + SFT	76.0%	96.2%	62.2%	71.3%

- 1 模型对每个问题生成 $G=8$ 个不同答案 $[S_1, S_2, \dots, S_8]$
↓
- 2 奖励模型打分： $[r_1=0, r_2=1, r_3=0, \dots, r_8=0]$ — 两个正确
↓
- 3 GRPO 在组内标准化 Advantage ($A_i = r_i - \text{mean}(r)/\text{std}(r)$)，无需 Critic 网络
↓
- 4 更新 π_θ ，下次生成更多正确答案（PPO-style clip 防止更新过激）

核心创新：用组内均值 / 标准差替代 Critic 网络估计 Advantage，大幅降低训练开销！



准确性奖励

- 二元判断：答案对 / 错
- 最简单也最有效
- 模型学会在错误后反思并纠正

过程奖励

- 给推理每一步打分
- 而非只看最终答案
- 帮助理解 " 哪一步走错 "

格式奖励

- 强制
<think>...</think>
; 标签
- 确保输出可解析
- 鼓励更完整的思考链

76.0%


AIME 2024 (数学竞赛)
超越 OpenAI o1 (74.6%)

96.2%

MATH-500
顶尖数学基准

62.2%

LiveCodeBench
代码生成基准
超越 o1 (52.3%)



关键发现：奖励信号是最关键因素（-35.4%）。纯 SFT 远不如 RL（-21.4%）。GRPO 本身贡献 +15.6%。

反思（Reflection）

模型主动回退并重新思考，"等等，让我重新考虑..."—从未被显式教过

长思维链

自发生成更长的思考过程。与 o1 异曲同工，但这里是纯 RL 涌现而非人工设计

问题分解

面对复杂问题，将问题拆解为子问题逐个攻克——高级元认知能力

验证（Verification）

在给出最终答案前，主动验证中间步骤的正确性，大大减少粗心错误

模型	AIME 2024	MATH-500	参数量	提升
Qwen2.5-7B (基座)	2.3%	14.3%	7B	—
DeepSeek-R1-Distill-Qwen-7B	52.5%	86.1%	7B	↑ 22×
Qwen2.5-32B (基座)	10.3%	47.8%	32B	—
DeepSeek-R1-Distill-Qwen-32B	72.6%	94.3%	32B	↑ 7×

当前局限

- 语言一致性：推理过程常出现中英文混合
- 函数调用 / 格式输出：不如专门的微调模型
- 训练成本：671B 参数训练门槛极高
- 冷启动数据：依赖人工后处理，难以自动化

未来方向

- 多模态推理：扩展到图像、视频、音频
- 更精细的奖励信号：过程奖励（每步打分）
- 多智能体 RL 推理：假设 + 验证 + 整合协作
- 推理效率优化：降低长思维链的推理成本

首次证明纯 RL 可让大模型涌现推理能力，无需任何监督数据

GRPO 算法 + 四阶段训练管道 + 冷启动策略（技术创新）

全系列开源（7B~671B），benchmark 上追平甚至超越 OpenAI o1

核心启示：正确的奖励信号比标注数据更重要——模型会自己找到 " 如何推理 "